

教育背景

西南石油大学 · 计算机与软件学院
西南石油大学 · 计算机与软件学院

软件工程
计算机科学与技术

硕士在读
本科

2024.09 – 2027.06
2020.09 – 2024.06

专业能力

- 熟悉 LLM 基础原理与推理优化技术，掌握模型部署、量化压缩、投机解码及性能评测方法
- 具备 Agent 系统设计与开发经验，熟悉 Skill 开发、工具调用、上下文管理、多智能体协作及安全机制设计
- 掌握大模型微调技术体系，熟悉 SFT、LoRA、知识蒸馏、权重插值等方法，具备模型训练、评测优化与部署实践经验
- 英语能力：CET-4 512 分，CET-6 540 分，2024 年考研英语二 85 分，具备适应英文工作环境的能力

实习经历

北京知道创宇信息技术有限公司

2026.04 – 至今

面向 ToB 私有化部署的 DeepSeek 双 DGX Spark 分布式推理与性能优化

项目背景：面向 AiPy 企业智能体的本地模型服务需求，评估双 DGX Spark 作为 1~5 用户小规模企业部署节点的可行性，基于 DeepSeek-V4-Flash-0731 构建并测试高性能推理服务。

- 负责 2× NVIDIA DGX Spark (GB10) 的机房硬件部署与节点互联，完成双机管理网与计算网私网的 IP 配置。
- 基于 vLLM 搭建双 DGX Spark 分布式推理架构，采用 TP=2 部署 DeepSeek V4 Flash, rank0 对外提供 OpenAI-compatible API 并负责请求调度，rank1 作为 headless 计算节点参与跨机并行推理。
- 通过 QSFP + RoCE + NCCL 构建双机高速通信链路，优化 Tensor Parallel 跨节点集合通信性能，将 NCCL 总线带宽从 98 Gb/s 提升至 161 Gb/s (+64%)。
- 对齐模型 YaRN 校准上限实现 1M 长上下文推理，基于 nvfp4_ds_mla 降低 KV Cache 显存占用，并结合 PagedAttention、Chunked Prefill 与 Prefix Caching 优化长 Prompt 处理与前缀复用，提升内存效率与并发能力。
- 基于 EvalScope 开展 1~20 并发多轮 Agent 压测，DSpark 在目标 1~5 并发下较无投机解码实现单会话 Output Throughput 提升 71%~87%、TPOT 降低 42%~47%，5 并发达到 106.84 tok/s 聚合吞吐与 1.05 s TTFT。

基于 AiPy 智能体集市的项目视觉生成 Skill 设计与开发

项目背景：面向公司 AiPy 智能体集市生态建设需求，独立设计并开发项目视觉生成技能，实现智能体对项目内容的自动理解与视觉方案生成，支持 Logo、项目封面、社交分享图等物料制作，并完成产品化与集市接入。

- 设计涵盖项目分析、视觉规划、用户确认、渲染生成与结果校验的 Agent 工作流，自动解析 README、项目配置、入口代码及已有视觉资产，提取项目定位、核心功能与视觉语义，并据此规划多套视觉方案。
- 设计并实现 Human-in-the-loop 多阶段 Agent 工作流，沙箱目录产出 3 套 Logo 概念对比方案后硬性阻塞等待用户决策，未确认的品牌资产禁止流入下游产物，解决 Agent 在主观决策场景下擅自拍板的问题。
- 构建基于 LLM 文案、SVG 模板与 Chromium 截图的确定性渲染管线，通过实测文本宽度自动缩字，支持 CJK/RTL 多语言布局并实现像素级可复现输出，且不依赖生图模型，可适配任意 LLM，有效规避图像幻觉与模型绑定问题。
- 完成 Skill 的 AiPy 智能体集市适配与发布，作为 Showcase 用于公司内部及对外演示。

实习表现：整体工作表现与交付质量获得负责人认可，并收到转正留用意向沟通。

个人项目

Ledger-X：工具调用加速与安全治理的高性能清结算数字员工

[code](#)

技术栈：Python、FastAPI、DuckDB、SQL、Pydantic、vLLM

项目背景：面向支付平台与收单机构的商户清结算，针对 LLM 金额计算不可靠、工具调用延迟高以及权限与证据链难管理等问题，设计“受控工具选择 → 只读 SQL → 确定性计算 → 证据化回答”的多步骤 Agent，辅助清结算运营及财务对账人员定位差异。

- 基于 DuckDB 构建 10 万笔合成支付账本，以参数化只读 SQL 完成结算汇总、批次复算与 Agent 工具链校验。
- 设计模式感知草稿生成，解析工具 JSON Schema 与当前解码前缀，预测工具名、必填字段、枚举值、JSON key 及闭合符等稳定片段，并由目标模型逐 token 验证，降低结构化输出的重复解码成本。
- 实现检索增强推测，按工具 schema 与商户权限隔离检索空间，基于请求 hidden state 召回经结构校验的历史工具调用，匹配当前 token 后缀生成续写草稿，并由目标模型逐 token 验证，加速动态参数区域的生成。
- 实现分层上下文与记忆机制，由 working memory 维护当前任务状态，case memory 按商户隔离存储跨会话事实，retrieved context 按相关性召回历史证据，并通过字段白名单、显著性排序及上下文预算控制写入质量与提示长度。
- 设计只读工具与策略护栏，限制模型仅生成经 Pydantic 校验的工具调用，禁止直接提交 SQL 或执行资金及写库操作，并通过商户权限校验和日期范围约束控制执行边界，结合全链路记录支持审计与复盘。

- **实验评估**：在统一的 **Qwen3-14B-FP8** 配置下，以普通自回归生成为基线，对 400 个单步工具调用问题重复评测 3 轮，共完成 1,200 次请求。完整加速模式将 p50 延迟从 2132.8ms 降至 372.5ms，在保持 100% 正确率的同时实现 **5.7×** 加速。同时，在预热后的检索增强推测消融实验中，草稿覆盖率达到 100%，token 接受率为 **84.11%**。进一步在 80 条多步骤 Agent 任务上，端到端配对中位延迟降低 **19.95%**，表明单步解码收益能够有效传导至完整 Agent 流程。

ChatAnchor：开源参与 OpenAI Codex 官方 Issue 的会话恢复与记忆复用插件 marketplace code

技术栈：TypeScript、Node.js、VS Code Extension API、Git、SQLite、Zod、Vitest、GitHub Actions、pnpm

项目背景：针对  OpenAI 官方仓库 [Issue #26836](#) 反映的“项目路径变更导致历史会话失联”问题，并结合 Cursor Agent CLI、OpenCode 等 AI Coding Agent 中存在的同类会话路径绑定现象，以及不同 Agent 之间上下文难以复用的问题，独立设计并开发本地 VS Code 插件，实现项目身份持久化、历史会话恢复与跨 Agent 记忆复用。

- 通过稳定 **Project UUID** 持久化项目身份，并结合 Path Alias、Git Remote、Commit SHA 等多维证据进行会话匹配，按多级置信度实现项目迁移后的历史线程自动关联、候选推荐与人工纠错。
- 本地生成项目上下文包，完整保留 Codex、Cursor Agent CLI、OpenCode 等历史会话，并通过 @path 实现跨 Agent 记忆复用，使不同 Coding Agent 可在同一项目中继承既有上下文，实现持续规划与开发。
- 社区反馈：基于本插件的工作原理形成方案建议，以 [comment #5558363522](#) 形式提交至 OpenAI 官方仓库。

科研成果

PROSE：面向 LLM KV Cache 共享 CXL 内存池的对象准入机制

- **论文信息**：第二作者，已投稿至计算机体系结构领域 CCF-A 类顶级会议 **HPCA 2027**（在审）
- **问题定义**：面向长上下文 LLM Serving 的 CXL KV Cache 共享内存池，发现并定义 **Reclaimed Payload Exposure**（回收后载荷暴露，RPE）：异步读排队期间目标槽位被回收复用，请求返回地址合法、缓存一致、却属于错误对象的数据。对生产系统 Mooncake Store（[commit f20b706](#)，含官方 2026 修复）的审计与真实负载重放证实租约防护存在固有局限：读后丢弃最忙时浪费 **49%** 读带宽，官方修复仍未覆盖异步引擎。
- **提出对象准入事务**：针对检查与发送之间的回收竞态窗口，将准入点从主机侧前移至 CXL 内存扩展器（endpoint）控制器数据路径，于数据发出前的最后一拍原子完成版本核验与锁定，校验失败即拒绝、错误数据不上链路；进一步采用仅覆盖传输期的短锁，排队期间槽位照常回收、不牺牲池化容量，并复用 CXL 标准接口实现、零改动互连协议。
- **实验评估**：在 BurstGPT 真实负载与真实系统审计下，Mooncake 现有机制需锁死 **39.3%** 池容量才能根治误读；PROSE 经模拟、RTL、形式化跨层验证，在相同负载下将误读其他对象 KV Cache 的字节降为 **0%**，同时保持 **93.8%** 池容量可回收，取得 **3.1×** 端到端加速。

LumiSense：基于轻量大模型的工业 IoT 边缘根因诊断框架 weights（下载量 182）

- **论文信息**：第一作者
- **问题定义**：针对工业 IoT 场景中设备状态数据异构、运行信息不完整以及故障类型持续演化等问题，传统分类模型受限于固定标签空间，难以应对未知故障与跨场景泛化；同时大参数量 LLM 存在部署成本高、难以适配边缘设备的问题。因此，研究大模型能力向轻量语言模型（SLM）迁移的方法，实现资源受限环境下高效可靠的故障根因诊断。
- **核心方法**：基于 **Qwen3.5-0.8B** 构建轻量化诊断模型，通过 LoRA-SFT 注入工业故障诊断知识与结构化推理能力，并利用 **Qwen3.5-27B** 教师模型进行知识蒸馏，迁移大模型诊断能力；进一步采用 **WiSE-FT** 对 SFT 与 KD 阶段 LoRA 适配器进行权重插值，提升模型在未知故障类型下的泛化能力。
- **实验评估**：在 1600 条训练数据上完成模型适配，优化后的 SLM 经 320 条独立测试样本评测，取得 **0.949** Macro-F1 与 100% 严格 JSON 输出率，性能逼近 Qwen3.5-27B 教师模型，并超越 GLM-4-32B、Gemma-4-31B 等 30B 级参数量模型。同时，在仅引入 0.037 Macro-F1 性能损失的前提下，完成 Q4_K_M GGUF 量化部署（529MB），并于 Apple Silicon（ARM64 CPU）环境下达到 **115 tok/s** 推理速度与 1.135 GiB 峰值内存占用，最后结合置信度路由构建边云协同诊断机制，在 42.5% 边缘覆盖率场景下，将 Macro-F1 提升至 0.966（+0.054）。

其他成果

1. SCI 一区论文一篇（学生一作，在投 *EAAI*）：传感器网络数据异常检测方向
2. SCI 二区论文一篇（学生二作，[Early Access](#), *IEEE Sensors Journal*）：结构健康监测数据完整性方向
3. IEEE MLNLP 会议论文一篇（第二作者，[已发表](#)）：物联网跨设备数据安全方向
4. 一项发明专利已进入实质审查阶段（202610620996.9），一项软件著作权已登记（2025SR0034269）

荣誉与证书

- **MOOC 认证**：自学 LLM & Agent 相关技术，并在 Coursera、Udemy、Harvard、DeepLearning.AI 等平台取得 [多项课程证书](#)
- **竞赛**：“微岩精灵：薄片微观图像全自动鉴定引领者”获“建行杯”四川省国际大学生创新大赛（2025）**铜奖**
- **勘误致谢**：向《C++ 实战：核心技术与最佳实践》配套仓库 [报告示例代码缺陷](#)，被作者采纳并署名收录于官方 [勘误表](#)
- **奖学金**：2024、2025 学年研究生三等学业奖学金，本科期间获院级二等、三等奖学金各一次