



教育背景

西南石油大学 · 计算机与软件学院
西南石油大学 · 计算机与软件学院

软件工程
计算机科学与技术

硕士在读
本科

2024.09 – 2027.06
2020.09 – 2024.06

实习经历

北京知道创宇信息技术有限公司

2026.04 – 至今

面向 To-B 智能体服务的双 DGX Spark 大模型推理部署与性能优化

- 项目背景：面向 AiPy 企业智能体的本地模型服务需求，评估双 DGX Spark 作为 1~10 用户小规模企业部署节点的可行性，基于 DeepSeek-V4-Flash-0731 构建并测试高性能推理服务。
- 负责 2× NVIDIA DGX Spark (GB10) 的机房硬件部署与节点互联，完成双机网络及 NCCL/RoCE 跨节点通信配置。
- 基于 vLLM 搭建 DeepSeek-V4-Flash-0731 分布式推理服务，采用 Tensor Parallel TP=2、FP8/MxFP4 权重与 NVFP4 KV Cache，完成 DSpark 推测解码部署。
- 基于 EvalScope 构建 1~20 并发多轮 Agent 负载测试，对 TTFT、TPOT、单会话/聚合生成吞吐等指标进行系统评估；在目标 1~10 并发区间，DSpark 相比无投机解码将单会话 OutTPS 提升 84%~88%，TTFT 降低 32%~47%。
- 在 10 并发场景下实现约 150 tok/s 聚合输出吞吐、15 tok/s 单会话吞吐及 1.61 s TTFT；进一步通过压力测试定位 20 并发下的排队与首 Token 延迟拐点，为 To-B 部署的容量规划与硬件选型提供依据。

面向 AiPy 智能体集市生态的项目视觉生成 Skill 设计与开发

- 项目背景：面向公司 AiPy 智能体集市生态建设需求，独立设计并开发项目视觉生成 Skill，使 Agent 自动理解项目并生成 Logo、README Cover、Social Preview 等视觉物料，完成 Skill 产品化与集市接入。
- 设计 Project Analysis → Visual Planning → User Confirmation → Rendering → Validation 的 Agent 工作流，自动解析 README、项目配置、入口代码及已有视觉资产，提取项目定位、核心功能与视觉语义，并据此规划多套视觉方案。
- 将 LLM 语义理解/视觉决策与确定性渲染解耦，基于 Python + SVG + Playwright 构建标准化渲染链路，支持 Logo、Cover、宣传图等多类物料生成，并通过尺寸、格式、路径及覆盖校验保证输出稳定性与可复现性。
- 完成 Skill 的 AiPy 智能体集市适配与发布，封装为可安装、可复用的 Agent 能力组件，丰富 AiPy 智能体生态。

个人项目

E-Snap：面向电商客服的两级语义缓存增强 RAG 智能体

[code](#) [demo](#)

- 技术栈：Python、FastAPI、LangGraph、LangChain、RedisVL / Redis Stack
- 项目背景：面向电商客服中高频问题重复检索、LLM 调用成本高及动态问题错误缓存复用等问题，设计两级语义缓存增强 RAG 智能体，通过缓存复用与动态路由降低响应延迟及模型调用成本。
- 设计 Dynamic Query Guard → L1 Rule Cache → L2 Semantic Cache → LLM Validator → ReAct RAG 分层工作流：L1 基于归一化、编辑距离及子问题匹配复用高置信度历史答案，L2 进行语义相似召回，并由 Validator 判断直接复用、信息补全或回退完整 RAG。
- 基于 RedisVL / Redis Stack 构建向量缓存与知识检索模块，结合 Vector Search + Keyword Search 实现混合检索及高频 FAQ 预热；缓存无法覆盖时通过 ReAct Agent 完成知识查询，并将可复用结果按规则写回缓存形成闭环。
- 实验评估：30 条离线请求上缓存覆盖率 42.31%、直接复用率 30.77%；相较纯 RAG，端到端延迟降低 26.64%、吞吐提升至 1.36×，平均减少 1.14 次/请求 LLM 调用，总体费用降低 32.36%。

ChatAnchor：面向 AI Coding Agent 的跨路径会话恢复工具

[code](#) [marketplace](#)

- 技术栈：TypeScript、Node.js、VS Code Extension API、Git、SQLite、Zod、Vitest、GitHub Actions
- 项目背景：针对 Codex、Cursor Agent、OpenCode 等 AI Coding Agent 会话与项目工作目录强绑定、项目重命名或迁移后历史线程难以恢复的问题，独立设计并开发本地 VS Code 插件 ThreadRelink，实现 Agent 会话与项目路径解耦。
- 设计路径无关的项目身份机制，通过稳定 Project UUID 持久化项目身份，并结合 Path Alias、Git Remote、Commit SHA 等多维证据进行会话匹配与置信度判定，实现项目迁移后的历史线程自动关联、候选推荐与人工纠错。
- 抽象多 Agent Provider 层，统一适配 Codex App Server、Cursor Agent 本地会话及 OpenCode SQLite 数据库，封装会话发现、关联与 Resume 流程，在新工作目录下继续原有 Agent 上下文。
- 采用 TypeScript Monorepo 分离 Core 与 VS Code UI，设计 Registry Schema 版本迁移、文件锁与原子写入机制保障本地状态一致性；接入 Vitest、ESLint、TypeCheck 及 Windows/macOS/Linux 三平台 CI，完成 VSIX 打包。

科研成果

PROSE：面向 LLM KV Cache 共享 CXL 内存池的安全对象访问机制

[code](#)

- 论文信息：第二作者，已投稿至 HPCA 2027（在审）

- **问题定义**: 面向长上下文 LLM Serving 的 KV Cache CXL 共享内存池, 发现并定义 **Reclaimed Payload Exposure (RPE)**: 异步请求排队期间发生 Slot Reuse 后, 可能返回地址合法且 Cache Coherent、但属于其他对象版本的数据; 公开 LLM Trace 实验中未保护路径存在 **11.2%~14.4% Stale Payload**。
- **核心机制**: 提出 **Object Admission Transaction (OAT)**, 在 CXL Endpoint 的 Payload Admission 阶段通过单一 CAS 线性化点原子完成对象版本 Validate + Transfer-scoped Pin, 失效 Descriptor 直接 Zero-Payload Reject, 在不修改 CXL Payload Protocol 的前提下消除 Check-to-Issue 竞争窗口。
- **实验评估**: 基于 SimCXL、RTL Co-simulation、TLA+、公开 LLM Trace 及 Mooncake Store 完成跨层验证; PROSE 实现 **0% Stale Payload**, 32× Oversubscription 下保持 **93.8%** 可回收容量并取得最高 **3.1×** 端到端加速, OAT 硬件开销仅 **9 ns / 0.0061 mm² / 5.83 mW**。

LumiSense: 面向工业 IoT 网关的轻量级大模型边缘根因诊断框架

🤖 weights (下载量 91)

- **论文信息**: 第一作者
- **问题定义**: 针对工业 IoT 场景中设备状态数据异构、运行信息不完整以及故障类型持续演化等问题, 传统分类模型受限于固定标签空间, 难以应对未知故障与跨场景泛化; 同时大参数量 LLM 存在部署成本高、难以适配边缘设备的问题。因此, 研究大模型能力向轻量语言模型 (SLM) 迁移的方法, 实现资源受限环境下高效可靠的故障根因诊断。
- **核心方法**: 基于 Qwen3.5-0.8B 构建轻量化诊断模型, 通过 LoRA-SFT 注入工业故障诊断知识与结构化推理能力, 并利用 Qwen3.5-27B 教师模型进行知识蒸馏, 迁移大模型诊断能力; 进一步采用 *WiSE-FT* 对 SFT 与 KD 阶段 LoRA 适配器进行权重插值, 提升模型在未知故障类型下的泛化能力。
- **实验评估**: 在自主构建的 CARES 工业传感器故障合成数据集上, 优化后的 SLM 取得 0.949 Macro-F1 与 100% 严格 JSON 输出率, 性能逼近 Qwen3.5-27B 教师模型并超越 GLM-4-32B、Gemma-4-31B 等 30B 级大参数模型。同时在仅引入 0.037 Macro-F1 性能损失的前提下, 完成 Q4_K_M GGUF 量化部署 (529MB), 在 Apple Silicon (ARM64 CPU) 环境下达到 115 tok/s 推理速度与 1.135 GiB 峰值内存占用。最后, 在此基础上引入置信度路由构建边云协同诊断机制, 于 42.5% 边缘覆盖率场景下将 Macro-F1 从 0.912 提升至 0.966 (+0.054)。

其他成果

1. SCI 一区论文一篇 (学生一作, 在投 *EAAI*): 传感器网络数据异常检测方向
2. SCI 二区论文一篇 (学生二作, [Early Access](#), *IEEE Sensors Journal*): 结构健康监测数据完整性方向
3. IEEE MLNLP 会议论文一篇 (第二作者, [已发表](#)): 物联网跨设备数据安全方向
4. 一项发明专利已进入实质审查阶段 (202610620996.9), 一项软件著作权已登记 (2025SR0034269)

专业能力

- 熟悉 LLM 基础原理与推理优化技术, 掌握模型部署、量化压缩、投机解码及性能评测方法
- 具备 Agent 系统设计与开发经验, 熟悉 Skill 开发、工具调用、上下文管理、多智能体协作及安全机制设计
- 掌握大模型微调技术体系, 熟悉 SFT、LoRA、知识蒸馏、WiSE-FT 等方法, 具备模型训练、评测优化与部署实践经验
- **英语能力**: CET-4 **512** 分, CET-6 **540** 分, 2024 年考研英语二 **85** 分, 具备适应英文工作环境的能力

奖项与证书

- **MOOC 认证**: 自主学习大模型应用开发最新技术, 并在 Coursera、Udemy、Harvard 等平台取得[多项课程证书](#)
- **竞赛**: “建行杯”四川省国际大学生创新大赛 (2025) **铜奖** (微岩精灵-薄片微观图像全自动鉴定引领者)
- **奖学金**: 2024、2025 学年研究生三等学业奖学金, 本科期间获院级二等、三等奖学金各一次