



教育背景

西南石油大学 · 计算机与软件学院
西南石油大学 · 计算机与软件学院

软件工程
计算机科学与技术

硕士在读
本科

2024.09 – 2027.06
2020.09 – 2024.06

专业能力

- 熟悉 LLM 基础原理与推理优化技术，掌握模型部署、量化压缩、投机解码及性能评测方法
- 具备 Agent 系统设计与开发经验，熟悉 Skill 开发、工具调用、上下文管理、多智能体协作及安全机制设计
- 掌握大模型微调技术体系，熟悉 SFT、LoRA、知识蒸馏、权重插值等方法，具备模型训练、评测优化与部署实践经验
- 英语能力：CET-4 512 分，CET-6 540 分，2024 年考研英语二 85 分，具备适应英文工作环境的能力

实习经历

北京知道创宇信息技术有限公司

2026.04 – 至今

面向 ToB 私有化部署的 DeepSeek 双 DGX Spark 分布式推理与性能优化

项目背景：面向 AiPy 企业智能体的本地模型服务需求，评估双 DGX Spark 作为 1~5 用户小规模企业部署节点的可行性，基于 DeepSeek-V4-Flash-0731 构建并测试高性能推理服务。

- 负责 2× NVIDIA DGX Spark (GB10) 的机房硬件部署与节点互联，完成双机管理网与计算网私网的 IP 配置。
- 基于 vLLM 搭建双 DGX Spark 分布式推理架构，采用 TP=2 部署 DeepSeek V4 Flash，rank0 对外提供 OpenAI-compatible API 并负责请求调度，rank1 作为 headless 计算节点参与跨机并行推理。
- 通过 QSFP + RoCE + NCCL 构建双机高速通信链路，优化 Tensor Parallel 跨节点集合通信性能，将 NCCL 总线带宽从 98 Gb/s 提升至 161 Gb/s (+64%)。
- 对齐模型 YaRN 校准上限实现 1M 长上下文推理，基于 nvfp4_ds_mla 降低 KV Cache 显存占用，并结合 PagedAttention、Chunked Prefill 与 Prefix Caching 优化长 Prompt 处理与前缀复用，提升内存效率与并发能力。
- 基于 EvalScope 开展 1~20 并发多轮 Agent 压测，DSpark 在目标 1~5 并发下较无投机解码实现单会话 Output Throughput 提升 71%~87%、TPOT 降低 42%~47%，5 并发达到 106.84 tok/s 聚合吞吐与 1.05 s TTFT。

基于 AiPy 智能体集市的项目视觉生成 Skill 设计与开发

项目背景：面向公司 AiPy 智能体集市生态建设需求，独立设计并开发项目视觉生成技能，实现智能体对项目内容的自动理解与视觉方案生成，支持 Logo、项目封面、社交分享图等物料制作，并完成产品化与集市接入。

- 设计涵盖项目分析、视觉规划、用户确认、渲染生成与结果校验的 Agent 工作流，自动解析 README、项目配置、入口代码及已有视觉资产，提取项目定位、核心功能与视觉语义，并据此规划多套视觉方案。
- 设计并实现 Human-in-the-loop 多阶段 Agent 工作流，沙箱目录产出 3 套 Logo 概念对比方案后硬性阻塞等待用户决策，未确认的品牌资产禁止流入下游产物，解决 Agent 在主观决策场景下擅自拍板的问题。
- 构建基于 LLM 文案、SVG 模板与 Chromium 截图的确定性渲染管线，通过实测文本宽度自动缩字，支持 CJK/RTL 多语言布局并实现像素级可复现输出，且不依赖生图模型，可适配任意 LLM，有效规避图像幻觉与模型绑定问题。
- 完成 Skill 的 AiPy 智能体集市适配与发布，作为 Showcase 用于公司内部及对外演示。

实习表现：整体工作表现与交付质量获得负责人认可，并收到转正留用意向沟通。

个人项目

Ledger-X：结构化工具调用加速的可验证对账引擎

[code](#)

技术栈：Python、FastAPI、DuckDB、Pydantic、vLLM、OpenAI-compatible API

项目背景：面向商户结算对账场景，解决 LLM 直接计算金额不可靠、工具调用生成慢、对账证据难追踪等问题，将自然语言问题拆解为受控工具选择 → 确定性账务计算 → 证据化回答生成的流程。

- 设计 Schema-Aware Drafting，根据工具 JSON Schema 和当前已生成内容，提前生成工具名、必填字段、枚举值、JSON key 和括号等结构化片段，再由同一个目标模型逐 token 验证，减少模型在固定格式输出上的重复生成成本。
- 设计 Retrieval-Augmented Speculation，把历史中已验证通过的完整工具调用按工具 schema、商户范围和上下文特征写入检索记忆，遇到相似问题只召回工具调用文本草稿，而不复用金额结果或最终答案，兼顾加速与账务正确性。
- 基于 DuckDB 构建可复现的合成账本，覆盖支付流水、退款流水、结算批次、手续费规则、结算明细和到账凭证，并在数据生成时同步保存标准答案，用于自动校验批次差额、异常原因、工具链和最终回答是否正确。
- 构建 working memory、case memory 和 retrieved context 三类上下文，只把工具返回的批次号、交易号、规则号、差额和异常类型等结构化证据写入记忆，避免模型自由文本污染长期记忆。
- 将所有工具封装为只读接口，Agent 会校验授权商户范围、拦截写操作意图、限制日期范围，并记录每轮模型消息、工具调用、工具结果、策略判定、记忆读写和耗时，便于复盘完整执行过程。

- **实验评估**：在基于同一套 Qwen3-14B-FP8 推理服务下，400 个单步工具调用问题重复 3 轮共 1,200 次，p50 延迟从普通自回归生成基线的 2143.3ms 降至 371.1ms，约 **5.8×** 加速且工具调用正确率保持 100%；进一步把该加速带入完整流程后，80 条独立构造的多步骤 Agent test 任务端到端中位延迟下降 **19.95%**。

ChatAnchor：开源参与 OpenAI Codex 官方 Issue 的会话恢复插件

 marketplace  code

技术栈：TypeScript、Node.js、VS Code Extension API、Git、SQLite、Zod、Vitest、GitHub Actions、pnpm

项目背景：针对  OpenAI 官方仓库 [Issue #26836](#) 反映的“项目文件夹重命名后现有线程工作目录失效”问题，以及 Cursor Agent CLI、OpenCode 等 AI Coding Agent 普遍存在的会话与项目路径强绑定问题，独立设计并开发本地 VS Code 插件，实现 Agent 会话与项目路径解耦。

- 通过稳定 **Project UUID** 持久化项目身份，并结合 Path Alias、Git Remote、Commit SHA 等多维证据进行会话匹配，按多级置信度实现项目迁移后的历史线程自动关联、候选推荐与人工纠错。
- 统一适配 Codex App Server、Cursor Agent CLI 本地元数据及 OpenCode SQLite 数据库，封装会话发现、关联与 Resume 流程，在新工作目录下继续原有 Agent 上下文。
- **社区反馈**：基于本插件的工作原理形成方案建议，以 [comment #5558363522](#) 形式提交至 OpenAI 官方仓库。

科研成果

PROSE：面向 LLM KV Cache 共享 CXL 内存池的对象准入机制

 code

- **论文信息**：第二作者，已投稿至计算机体系结构领域 CCF-A 类顶级会议 **HPCA 2027**（在审）
- **问题定义**：面向长上下文 LLM Serving 的 CXL KV Cache 共享内存池，发现并定义 **Reclaimed Payload Exposure**（回收后载荷暴露，RPE）：异步读排队期间目标槽位被回收复用，请求返回地址合法、缓存一致、却属于错误对象的数据。对生产系统 Mooncake Store（[commit f20b706](#)，含官方 2026 修复）的审计与真实负载重放证实租约防护存在固有限制：读后丢弃最忙时浪费 **49%** 读带宽，官方修复仍未覆盖异步引擎。
- **提出对象准入事务**：针对检查与发送之间的回收竞态窗口，将准入点从主机侧前移至 CXL 内存扩展器（endpoint）控制器数据路径，于数据发出前的最后一拍原子完成版本核验与锁定，校验失败即拒绝、错误数据不上链路；进一步采用仅覆盖传输期的短锁，排队期间槽位照常回收、不牺牲池化容量，并复用 CXL 标准接口实现、零改动互连协议。
- **实验评估**：在 BurstGPT 真实负载与真实系统审计下，Mooncake 现有机制需锁死 **39.3%** 池容量才能根治误读；PROSE 经模拟、RTL、形式化跨层验证，在相同负载下将误读其他对象 KV Cache 的字节降为 **0%**，同时保持 **93.8%** 池容量可回收，取得 **3.1×** 端到端加速。

LumiSense：面向工业 IoT 网关的轻量大模型边缘根因诊断框架

 weights（下载量 169）  code

- **论文信息**：第一作者
- **问题定义**：针对工业 IoT 场景中设备状态数据异构、运行信息不完整以及故障类型持续演化等问题，传统分类模型受限于固定标签空间，难以应对未知故障与跨场景泛化；同时大参数量 LLM 存在部署成本高、难以适配边缘设备的问题。因此，研究大模型能力向轻量语言模型（SLM）迁移的方法，实现资源受限环境下高效可靠的故障根因诊断。
- **核心方法**：基于 Qwen3.5-0.8B 构建轻量化诊断模型，通过 LoRA-SFT 注入工业故障诊断知识与结构化推理能力，并利用 Qwen3.5-27B 教师模型进行知识蒸馏，迁移大模型诊断能力；进一步采用 *WiSE-FT* 对 SFT 与 KD 阶段 LoRA 适配器进行权重插值，提升模型在未知故障类型下的泛化能力。
- **实验评估**：在 1600 条训练数据上完成模型适配，优化后的 SLM 经 320 条独立测试样本评测，取得 **0.949** Macro-F1 与 100% 严格 JSON 输出率，性能逼近 Qwen3.5-27B 教师模型，并**超越** GLM-4-32B、Gemma-4-31B 等 30B 级参数量模型。同时，在**仅引入 0.037** Macro-F1 性能损失的前提下，完成 Q4_K_M GGUF 量化部署（529MB），并于 Apple Silicon（ARM64 CPU）环境下达到 **115 tok/s** 推理速度与 1.135 GiB 峰值内存占用，最后结合置信度路由构建边云协同诊断机制，在 42.5% 边缘覆盖率场景下，将 Macro-F1 提升至 0.966（**+0.054**）。

其他成果

1. SCI 一区论文一篇（学生一作，在投 *EAAI*）：传感器网络数据异常检测方向
2. SCI 二区论文一篇（学生二作，[Early Access](#), *IEEE Sensors Journal*）：结构健康监测数据完整性方向
3. IEEE MLNLP 会议论文一篇（第二作者，[已发表](#)）：物联网跨设备数据安全方向
4. 一项发明专利已进入实质审查阶段（202610620996.9），一项软件著作权已登记（2025SR0034269）

奖项与证书

- **MOOC 认证**：自学 LLM & Agent 相关技术，并在 Coursera、Udemy、Harvard、DeepLearning.AI 等平台取得[多项课程证书](#)
- **竞赛**：“建行杯”四川省国际大学生创新大赛（2025）**铜奖**（微岩精灵-薄片微观图像全自动鉴定引领者）
- **奖学金**：2024、2025 学年研究生三等学业奖学金，本科期间获院级二等、三等奖学金各一次